基于短时 GRU 关联网络的路侧雷达多扩展目标跟踪算法

徐安策[1,2]，王目光*[1,2]22，陈 欣[1,2]，苏 昊[1,2]，王 健[1,2]，孙 亮[1,2]

（1.北京交通大学全光网络与现代通信网教育部重点实验室，北京 100044；

2.北京交通大学光波技术研究所，北京 100044）

摘要：针对交通场景中路侧毫米波雷达扩展目标多点散射、目标密集交互以及杂波与漏检并存条件下的跟踪问题，本文提出一种基于短时门控循环单元（Gated Recurrent Unit，GRU）数据关联网络的路侧雷达多扩展目标跟踪算法。该方法将量测与航迹状态统一映射至共同状态空间，构造当前量测与候选航迹短历史状态之间的残差序列，并利用 GRU 提取短时动态一致性特征；同时引入虚拟目标类别和有效掩码机制，实现杂波判别、动态量测与航迹条件下的多量测归属及连续跟踪。仿真结果表明，所提算法在不同检测概率及综合复杂交通场景下均获得较小的 OSPA 距离、较高的 F1 值和较低的关联耗时，具有较好的关联精度、鲁棒性与实时性。

关键词：路侧毫米波雷达；扩展目标；数据关联；门控循环单元；多目标跟踪

中图分类号：TN953　　**文献标志码：**A　　**文章编号：**

Multi-Extended Target Tracking for Roadside Radar Based on a Short-Term GRU Association Network

XU Ance[1,2], WANG Muguang*[1,2], CHEN Xin[1,2], SU Hao[1,2], WANG Jian[1,2], SUN Liang[1,2]

（1.*Key Laboratory of All Optical Network and Advanced Telecommunication Network of Ministry of Education, Beijing Jiaotong University, Beijing 100044, China;*

2.*Institute of Lightwave Technology, Beijing Jiaotong University, Beijing 100044, China*）

Abstract: To address the tracking problem of extended targets in traffic scenarios, where roadside millimeter-wave radar measurements are characterized by multiple scattering points, dense target interactions, clutter, and missed detections, this paper proposes a multi-extended-target tracking algorithm for roadside radar based on a short-term Gated Recurrent Unit (GRU) data association network. Measurements and track states are first mapped into a common state space, and residual sequences between each current measurement and the short-term historical states of candidate tracks are constructed. The GRU then extracts short-term dynamic-consistency features. A dummy-target class and an effective masking mechanism are introduced to identify clutter and support multi-measurement assignment and continuous tracking with time-varying numbers of measurements and tracks. Simulation results show that the proposed algorithm achieves lower OSPA distances, higher F1 scores, and shorter association times under different detection probabilities and a comprehensive complex traffic scenario, demonstrating good association accuracy, robustness, and real-time performance.

Keywords: roadside millimeter-wave radar; extended target; data association; Gated Recurrent Unit; multi-target tracking

0 引 言

近年来，随着智慧交通系统与车联网的迅速发展，路侧传感器需要在复杂交通环境中实现对多目标跟踪(Multi-Target Tracking, MTT)的稳定感知与连续跟踪。路侧毫米波雷达因其全天候、远距离、速度敏感等优势，已经成为道路感知系统中的重要传感器。然而如图 1 所示，在真实交通场景中，毫米波雷达的回波往往呈现出多目标密集、扩展目标多点散

基金项目：国家自然科学基金（No.62371035）

最新录用

射以及杂波与漏检并存等特点[1]，对多目标跟踪任务提出了相应挑战。

路侧毫米波雷达杂波主要来源于道路护栏、地面反射、多径反射及随机虚警点。当杂波点与真实散射点在位置或径向速度上接近时，易造成误关联、航迹漂移和虚假航迹生成因此，在多点散射、目标密集和杂波干扰条件下实现稳定数据关联，是需要解决的关键问题。

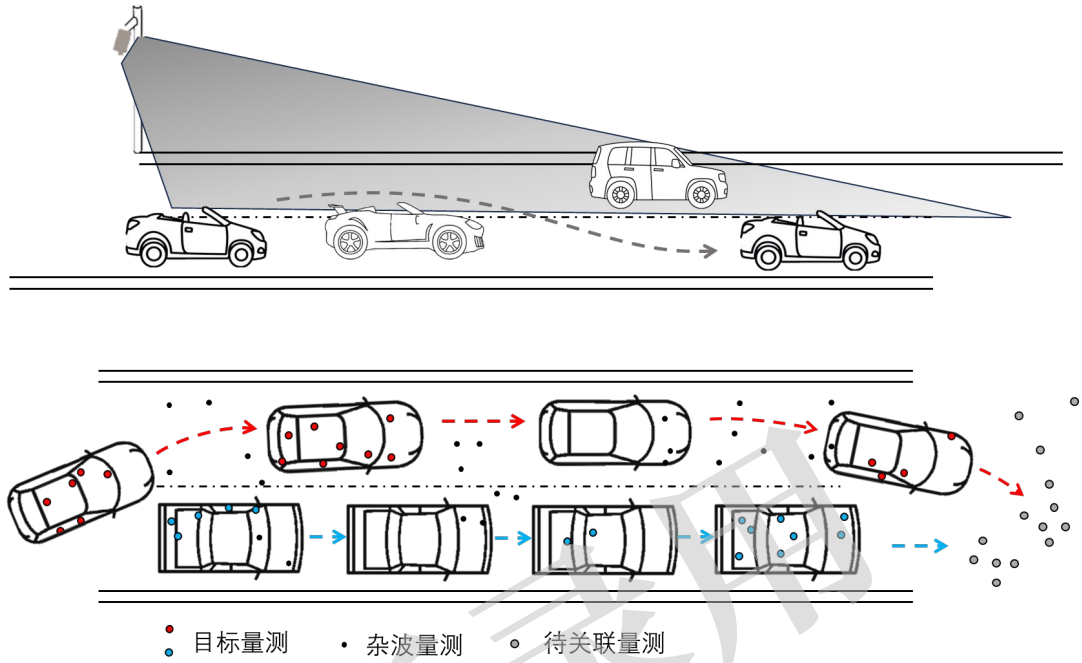


图 1 交通场景中多目标跟踪

Fig. 1 Multi-target tracking in traffic scenarios

在多目标跟踪任务中，数据关联模块起到实现目标与量测正确匹配的重要作用，它决定了每个量测应当用于更新哪一条航迹，或者应当被判定为杂波，或用于目标起始[2]。数据关联的错误将直接导致量测分配到错误航迹从而导致航迹漂移、断裂，并影响位置与速度估计精度。

现在传统数据关联方法大体可分为基于极大似然的确定性匹配和基于贝叶斯的概率推断两种方法。前者通常将多目标数据关联建模为线性指派问题(Linear Assignment Problem, LAP)，在门控约束下计算航迹预测与量测之间的代价，并寻找使总代价最小的一对一硬匹配。其中典型代表为匈牙利算法(Hungarian Algorithm, HA)[2]和全局最近邻算法(Global Nearest Neighbour, GNN)[4]，通过最大化总对数似然实现最优分配。在交通场景中，扩展目标的多点量测与杂波点容易落入门控范围，硬匹配机制一旦选错容易产生误更新。相比之下，贝叶斯类方法通过构造关联概率或假设集合来完成匹配，联合概率数据关联(Joint Probability Data Association, JPDA)[5]通过计算互联事件的概率获得每条航迹的边缘关联概率，从而进行软更新。然而当目标数量增多、波门重叠严重或者单帧量测点数增大时，联合事件数会快速膨胀，从而会导致组合爆炸问题，进而影响多目标跟踪系统的实时性。

近年来，数据驱动的深度学习方法为数据关联提供了新的思路[6]，神经网络可以从大量场景数据中学习到更复杂的判别规律。Milan 等人[7]提出了基于循环神经网络的算法来解决 LAP 问题，但该算法没有考虑传感器存在杂波和漏检的情况。Liu 等人[8]提出基于长短时记忆网络(Long Short-Term Memory, LSTM)的数据关联算法，在简单杂波环境下显示比 JPDA 和 HA 等经典算法具有更好的关联性能。Verma 等人[9]将双向长短时记忆网络(Bi-

directional Long Short Term Memory, Bi-LSTM)引入解决数据关联问题，结果显示比 LSTM 模型有更好的关联性能。Wu 等人[10]在此基础上提出基于改进的双向门控循环单元(Bidirectional Gated Recurrent Unit, BiGRU)模型的数据关联算法，结果显示在关联准确率以及运行时间方面都优于 HA 算法以及 LSTM 和 BiLSTM 模型。然而，上述研究大多利用卡尔曼滤波预测状态与当前帧量测构造残差特征，当模型参数不匹配或存在连续漏检时，预测状态可能偏离真实值，影响关联性能。除循环神经网络结构外，基于注意力机制的模型也被引入数据关联任务。李文娜等人[11]提出一种基于 Transformer 网络的多目标跟踪数据关联算法，从历史航迹与量测中学习关联关系。Liu 等人[12]进一步提出利用位置和多普勒信息提升关联能力的 Transformer 数据关联框架。然而，Transformer 类方法通常具有较高的计算复杂度，对硬件资源和训练数据规模要求较高，且现有研究在复杂机动场景下的验证仍相对有限。相比之下，Cho 等人提出的门控循环单元(Gated Recurrent Unit, GRU)[13]在保持较强时序特征建模能力的同时，简化了网络结构，减少了参数规模与计算复杂度，在多个领域得到了广泛应用[19][14]，为兼顾关联性能与实时性的目标跟踪任务提供了更具实用价值的技术选择。

针对交通场景中毫米波雷达扩展目标多点密集、多车交互以及杂波与漏检并存的数据关联问题，本文提出一种面向路侧毫米波雷达多扩展目标跟踪的短时 GRU 数据关联算法，从毫米波雷达量测机理出发，综合考虑量测点与目标航迹在位置、径向运动及短时动态变化上的一致性关系，构造量测与航迹短历史状态之间的残差序列，并引入虚拟目标类别进行杂波判别，从而增强密集目标场景下的关联稳定性，并兼顾交通场景多目标跟踪中对实时性的要求。本文主要贡献如下：

（1）提出了一种面向路侧毫米波雷达扩展目标数据关联的短历史残差序列表示方法，将量测状态与航迹状态统一到共同状态空间，并通过量测与候选航迹短历史状态之间的残差序列刻画二者的短时动态一致性。

（2）构建了带虚拟目标类别的短时 GRU 数据关联网络，利用 GRU 提取残差序列中的时序关联特征，并通过虚拟目标类别实现杂波量测判别和真实目标归属分类。

（3）引入适用于动态量测数和动态航迹数的有效 Mask 机制，并结合扩展目标多量测聚类更新，实现杂波、漏检和多散射点条件下的连续跟踪。

1 扩展目标数据关联问题建模

数据关联问题本质上是一个优化组合匹配问题，点云扩展目标场景下该分配由一对一匹配推广为量测与目标集合的多对一归属问题。这一问题从深度学习建模的角度来研究，则可以看作是一个多分类问题，即判定该量测属于哪一条目标轨迹，或者判定其为噪声量测。

路侧毫米波雷达量测数据由雷达回波信号处理获得。以 FMCW 毫米波雷达为例，回波信号经混频后形成中频信号，通过距离维 FFT、多普勒 FFT 和角度估计分别获得目标距离、径向速度、方位角和俯仰角，并经恒虚警检测和点云生成得到单帧量测点。本文仿真中依据上述点云量测机理，由车辆真实状态和扩展目标散射点模型生成量测，并叠加距离、角度和径向速度噪声，以模拟实际路侧毫米波雷达输出。

假设在一个场景中对N个目标进行跟踪，在时刻k获取的量测集合为：

$$Z_k=\left\{z_k^j\right\}_{j=1}^{M_k} \tag{1}$$

其中，M_k为雷达时刻k获取的量测数量，j为雷达时刻k获取的量测序号，z_k^j为第j个量测

在k时刻获取的状态信息为：

$$z_k^j=\left[r,\alpha,\beta,v_r,RCS\right]^T \tag{2}$$

其中，r表示径向距离，α为方位角，β为俯仰角，v_r为径向速度，RCS 为雷达散射截面积。给定时刻k跟踪的目标集合以及目标状态定义为：

$$X_k=\left\{x_k^i\right\}_{i=1}^{N_k} \tag{3}$$

$$x_k^i=\left[x,y,v_x,v_y\right]^T \tag{4}$$

其中，N_k为雷达时刻k获取的跟踪目标数量，i为雷达时刻k获取的轨迹序号，x,y,v_x,v_y分别为目标在笛卡尔坐标系下的位置以及速度分量。为了表示无目标与相应量测匹配，本文引入虚拟目标的概念，通过在时刻k增加一个序号为 0 的虚拟目标来重新定义目标集合X_k，当量测为噪声或者杂波时，将其关联至虚拟目标，从而将扩展目标数据关联问题定义为量测在N_k+1个类别中的归属判定问题。

关联算法的输出是定义在时刻k的关联矩阵为$A_k\in\left\{0,1\right\}^{(N¿¿k+1)\times M_k¿}$，其中每个元素$a_{ij}$表示目标$i$和量测$j$的关联关系：

$$a_{ij}=\begin{cases}1,\text{量测 }j\text{属于目标 }i\\0,\text{量测 }j\text{不属于目标 }i\end{cases} \tag{5}$$

其中由于一个量测最多只能分配给一个目标，而一个目标可以分配多个量测，因此关联矩阵的约束条件应满足：

$$\sum_{i=0}^{N_k}a_{ij}\le 1,\sum_{j=1}^{M_k}a_{ij}\ge 0 \tag{6}$$

本文所研究的数据关联模型旨在杂波、漏检以及扩展目标多量测并存的条件下，依据目标历史状态与当前量测之间的关系，解决扩展目标跟踪中当前时刻多量测集合与目标轨迹集合之间的归属分类问题。

2　基于短时 GRU 的扩展目标数据关联模型

路侧毫米波雷达扩展目标量测通常具有多散射点、空间分布离散、杂波点混入以及连续漏检等特点，仅依赖当前帧量测与预测状态之间的单帧差异，容易受到单次预测误差、目标短时机动和局部杂波点的影响。为此，本文将数据关联判定由单帧几何距离匹配扩展为短时动态一致性判别，提出的数据驱动短时 GRU 数据关联框架如图 2 短时 GRU 数据关联框架所示。该框架可在端到端训练中从样本中学习多量测与目标之间的匹配关系，从而以数据驱动方式替代传统依赖先验的组合优化求解。短时 GRU 数据关联模型以当帧量测集合Z_k和各目标的短历史状态序列$X_i^k=\left\{x_i(k-H:k-1)\right\}_{i=1}^{N_k}$作为输入，本文在统一状态基础上构造量测与目标短历史状态之间的残差序列，并将其作为网络的时序特征，通过 GRU 提取二者在短时间内的动态关联特征，进而输出量测对候选目标的关联概率。针对扩展目标

最新录用

单帧可产生多个量测点的特点，本文允许同一目标在同一时刻关联多个量测，目标通过多个关联量测聚类后的聚类量测对自身状态进行更新，并在下一时刻继续开展数据关联。

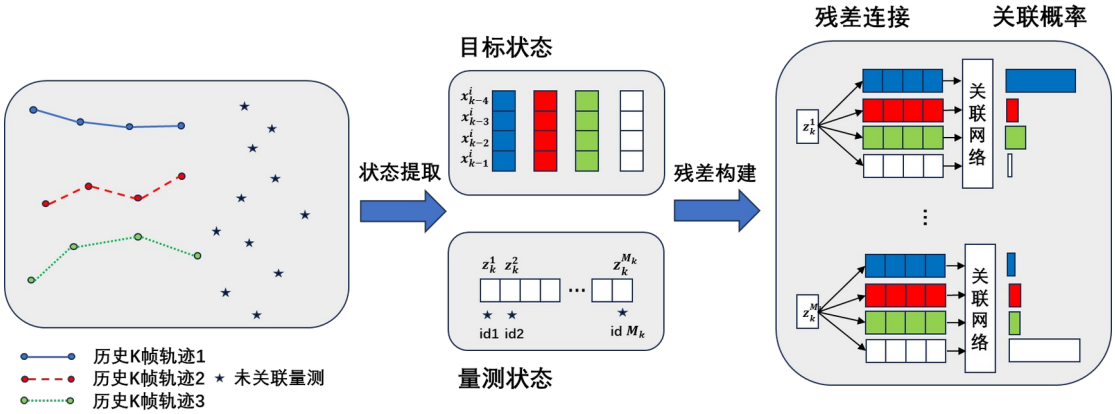


图 2 短时 GRU 数据关联框架

Fig. 2 Short-term GRU data association framework

2.1 输入表示与残差序列构造

与直接输入量测状态和目标状态相比，残差序列能够更直接表征二者在位置和速度上的相对偏差关系。但由于在构造量测与目标残差序列时需要在同一状态空间内进行逐维相减，而原始量测状态为r,α,β,v_r,RCS，目标航迹状态为x,y,v_x,v_y，两者在坐标系与速度定义上不一致，无法直接对齐。为此，本文将量测与目标状态统一转换到共同表示x,y,v_{xr},v_{yr}，其中v_{xr},v_{yr}表示径向速度在各坐标方向上的分量，从而保证残差可在同一物理意义下计算。量测侧由球坐标到笛卡尔坐标的转换为：

$$\begin{cases} x^z = r\cos\beta\sin\alpha \\ y^z = r\cos\beta\cos\alpha \\ v_{xr}^z = v_r\cos\beta\sin\alpha \\ v_{yr}^z = v_r\cos\beta\cos\alpha \end{cases} \tag{7}$$

$$z_k^j = \left[x^z, y^z, v_{xr}^z, v_{yr}^z\right]^T \tag{8}$$

其中，z_k^j表示第k帧第j个量测点状态，x^z, y^z分别表示该量测点在统一笛卡尔坐标系下的横向和纵向位置，v_{xr},v_{yr}分别表示该量测径向速度在横向和纵向方向上的投影分量。本文以雷达视场中心线方向为纵向y轴，以道路横向为x轴，方位角α为量测点相对于雷达主视向的水平偏角，俯仰角β用于修正地平面投影距离。

目标侧首先由位置得到视线方向单位向量，并将目标速度投影得到径向速度标量：

$$u = \frac{1}{\sqrt{x^2+y^2}}\begin{bmatrix} x \\ y \end{bmatrix} \tag{9}$$

$$v_r^x = u^\top \begin{bmatrix} v_x \\ v_y \end{bmatrix} = \frac{x v_x + y v_y}{\sqrt{x^2 + y^2}} \tag{10}$$

进而得到与量测一致的状态分量表示：

$$\begin{cases} x^x = x \\ y^x = y \\ v_{xr}^x = v_r^x \cdot u_x = \dfrac{x(x v_x + y v_y)}{x^2 + y^2} \\ v_{yr}^x = v_r^x \cdot u_y = \dfrac{y(x v_x + y v_y)}{x^2 + y^2} \end{cases} \tag{11}$$

$$x_k^i = \left[x^x, y^x, v_{xr}^x, v_{yr}^x \right]^T \tag{12}$$

其中，x_k^i表示第k帧第i个目标状态，x^x, y^x分别表示该目标在统一笛卡尔坐标系下的横向和纵向位置，v_{xr}^x, v_{yr}^x分别表示该目标径向速度在横向和纵向方向上的投影。

对于路侧毫米波雷达扩展目标场景而言，当前帧量测往往具有离散散射、多点分布和随机扰动等特点，仅依赖单帧难以稳定区分相邻目标与杂波量测。若结合连续若干帧历史信息，则可以从量测与航迹之间的位置变化、径向运动一致性以及局部运动连续性中提取更可靠的关联判据。为此，在完成统一表示后，对第i条航迹取最近$H=4$帧历史状态并按时间拼接，得到航迹历史矩阵：

$$X_i^k = ¿ \\ ¿$$

其中，H表示用于构造残差序列的历史状态长度，其取值会影响网络可利用的短时动态信息范围和计算开销。为分析该参数对关联性能的影响，本文在实验部分进一步对$H=1,2,4,8$进行了对比验证。x_i^t为航迹在时刻t的目标状态表示，D为统一状态维度，对每个量测z_k^j与航迹i的历史状态X_i^k，构造长度为H的残差序列：

$$R_{j,i}^k = repmat\left(z_k^j, H, 1\right) - X_i^k \in R^{H \times D} \tag{14}$$

其中，$repmat\left(z_k^j, H, 1\right)$表示将量测向量复制$H$次以与航迹历史对齐，之后将所有量测与所有航迹对应的残差序列堆叠得到：

$$Q^k = \left\{ R_{j,i}^k \right\}_{j=1,i=0}^{M_k, N_k} \in R^{M_k(N_k+1) \times H \times D} \tag{15}$$

Q^k即为输入的序列，每个输入样本为一个量测与目标的残差序列对。

与仅由当前预测状态和当前量测构造的单帧残差相比，短历史残差序列能够提供更加

最新版用

稳定的动态判别信息。当量测点真实属于某一航迹时，其与该航迹短历史状态之间的残差通常在连续时间内具有较好的变化连续性和径向运动一致性；而杂波点或相邻目标散射点虽然可能在某一帧内与候选航迹位置接近，但其在短时间窗口内往往难以保持一致的运动趋势。因此，短历史残差序列能够帮助网络区分真实关联量测、相邻目标散射点和杂波量测，从而降低密集目标和连续漏检条件下的误关联概率。

由于不同帧中量测点数M_k与有效航迹数N_k均随场景变化而不固定，本文对数据长度进行统一对齐，以最大量测数M_{max}与最大目标数N_{max}为基准，将各时刻的量测集合由$R^{M_k \times D}$扩展为$R^{M_{max} \times D}$，并将目标历史序列由$R^{N_k \times H \times D}$扩展为$R^{N_{max} \times H \times D}$，空位置以零值填充。

同时，为每个位置生成掩码有效标记以区分真实量测，真实航迹与填充项，掩码功能实现如图 3 掩码实现原理所示。训练时，量测填充位置在损失计算中被忽略。前向推理时，填充的目标在归一化计算前被赋予极小分数，使其概率近似为零，从而保证网络仅基于有效量测与有效目标进行学习与输出，从而支持量测点数和有效航迹数动态变化。

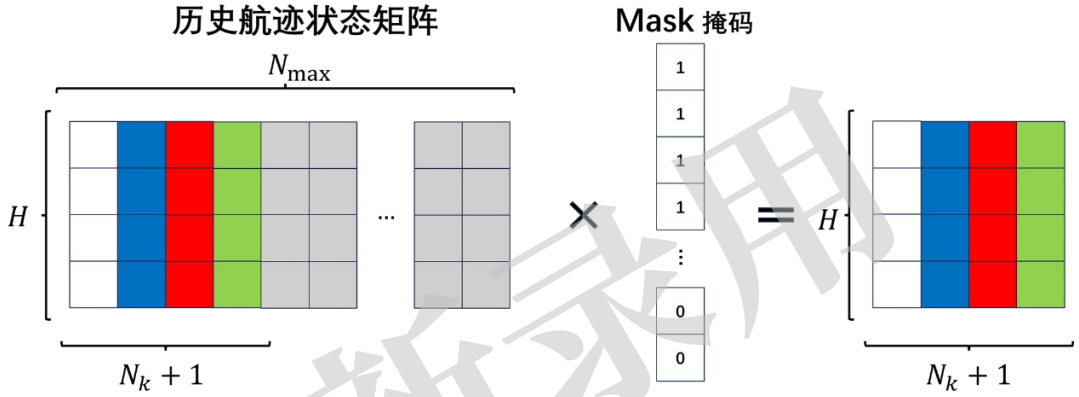


图 3 掩码实现原理

Fig. 3 Principle of the masking mechanism

2.2 短时 GRU 数据关联网络

在完成量测状态与目标历史状态的统一表示以及残差序列构造后，本文进一步设计短时 GRU 数据关联网络，GRU 结构在保持较强时序建模能力的同时，具有参数量较小、训练效率较高的特点，适合用于对实时性要求较高的路侧雷达多目标跟踪任务。图 4 展示了本文方法从当前量测集合与候选目标短历史状态输入，到统一状态映射、残差序列构造、GRU 特征编码、关联概率输出以及关联矩阵生成的完整计算流程，通过提取量测与候选目标之间的短时时序关联特征，输出各量测关于所有候选目标的关联概率，从而实现扩展目标场景下的多量测归属分类判定。

最新录用

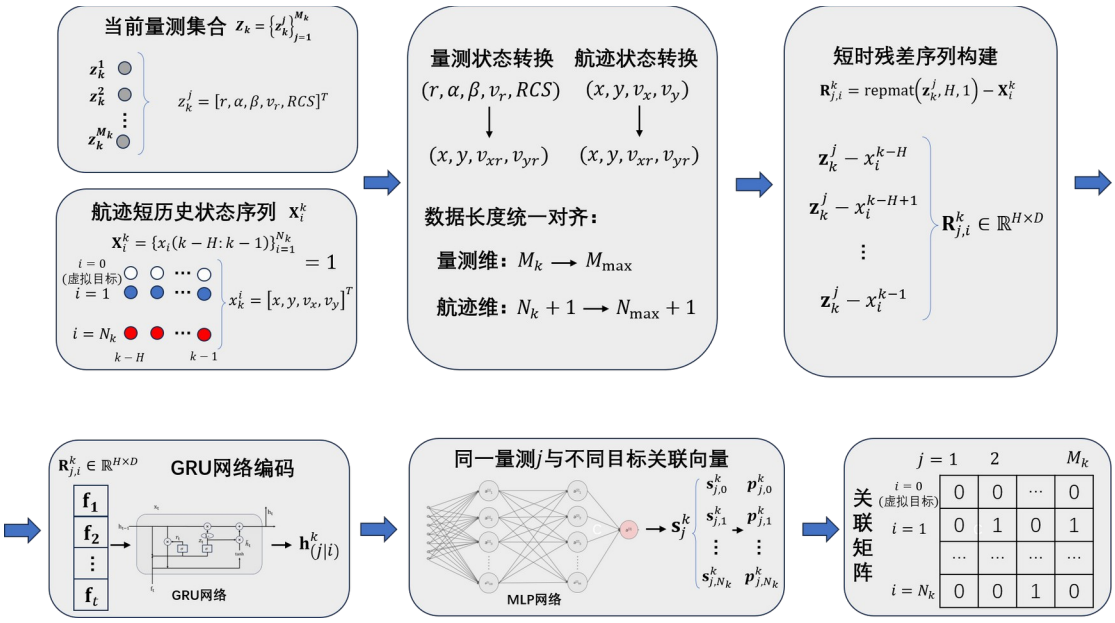


图 4 第 k 时刻短时 GRU 数据关联网络计算流程

Fig. 4 Computational procedure of the short-term GRU data association network at time k

具体在本文网络中，对于时刻k任意量测j与候选目标i，首先由前文构造其对应的短时残差序列$R_{j,i}^{k}\in R^{H\times D}$。该残差序列反映了当前量测与候选目标在连续$H$个时刻上的状态差异关系，可用于描述二者在几何位置、速度变化以及短时运动趋势等方面的一致性。本文将$R_{j,i}^{k}$视为长度为H的特征序列$\{f_t\}_{t=1}^{H}$，并输入短时 GRU 网络，以提取量测与候选目标之间的时序关联特征。

GRU 是 LSTM 的一种高效简化变体，它将 LSTM 的三个门结构简化为复位门r_t和更新门z_t结构，在保持 LSTM 时序建模能力的同时提高了网络的训练效率，相比 LSTM 和 Transformer，GRU 结构更简洁、计算开销更低，更符合路侧雷达实时数据关联需求。因而更适用于交通场景中对实时性要求较高的数据关联任务。模型结构如图 5 所示，其更新过程为：

$$\begin{cases} z_t=\sigma\left(W_z f_t+U_z h_{t-1}\right) \\ r_t=\sigma\left(W_r f_t+U_r h_{t-1}\right) \\ \tilde{h}_t=\tanh\left(W_h f_t+U_h\left(r_t\odot h_{t-1}\right)\right) \\ h_t=\left(1-z_t\right)\odot h_{t-1}+z_t\odot\tilde{h}_t \end{cases} \tag{16}$$

式中，σ为 Sigmoid 激活函数，tanh 为双曲正切函数，h_t,h_{t-1}为时间 t 和 t-1 的隐藏状态，W_z,U_z,W_r,U_r,W_h,U_h为权重矩阵。

在获得残差序列的编码结果后，本文取最后时刻的隐状态$h_{(j,i)}^{k}$作为残差序列的时序特征表示，并将其输入两层多层感知机(Multi-Layer Perceptron, MLP)[19]输出标量分数$s_{(j,i)}^{k}$，得分用于代表当前量测与候选目标之间的匹配程度，得分越大表示关联的可能性越高。再将

同一量测j关于所有候选目标$i\in\{0,1,\ldots,N_k\}$的分数堆叠为向量$s_j^k=[s_{(j,0)}^k,\ldots,s_{(j,n_k)}^k]$，通过softmax[20]得到关联概率分布：

$$p\left(y_j^k=i\,|\,z_j^k\right)=\frac{\exp\left(s_{(j,i)}^k\right)}{\sum_{c=0}^{N_k}\exp\left(¿\,s_{(j,c)}^k\right)¿}\quad(17)$$

其中，y_j^k 表示量测 z_k^j的关联类别标签。当$i=0$时，表示该量测被判定为杂波；当$i=1\ \ N_k$时，表示该量测与相应目标航迹关联。最后，依据最大概率判决准则确定量测的归属航迹，并将关联结果填入关联矩阵$A_k\in\{0,1\}^{(N¿¿k+1)\times M_k¿}$。由于扩展目标在单帧内可能产生多个散射点量测，本文允许同一目标在同一时刻关联多个量测，从而为后续聚类量测更新提供支持。

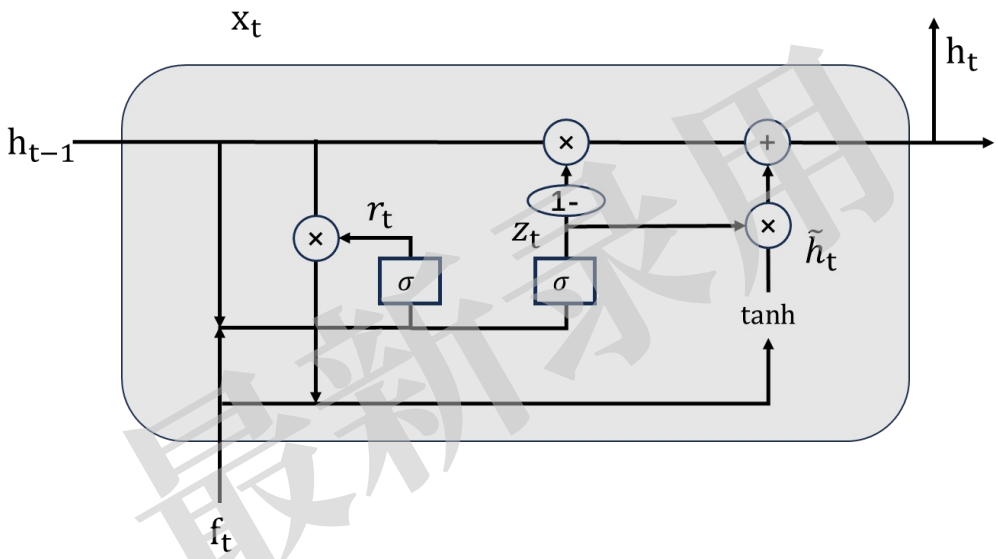


图 5 GRU 模型结构

Fig. 5 Structure of the GRU model

2.3 损失函数设计

本文将数据关联建模为量测到候选目标的多类别分类问题，网络对第j个量测输出其属于N_k+1个类别的关联得分。因此，交叉熵损失与 Softmax 概率输出相匹配，可直接约束网络提高真实关联类别的预测概率。考虑到不同帧量测数M_k与航迹数N_k动态变化，本文引入 Mask 项，仅对有效量测计算损失，避免填充项影响训练。同时，为缓解目标类与杂波类不平衡问题，对杂波类引入权重系数λ_c，增强网络对非关联量测的判别能力。因此，加权 Mask 交叉熵更适用于路侧毫米波雷达扩展目标数据关联任务，其损失函数定义为：

$$L=\sum_k\frac{\sum_j\omega\left(¿¿y_{k,j}\right)\,CE\left(l_{k,j},y_{k,j}\right)\cdot M\,ask_{k,j}}{\sum_k\sum_j\omega\left(¿¿y_{k,j}\right)\cdot M\,ask_{k,j}+\varepsilon¿}¿¿\quad(18)$$

¿

其中$l_{k,j}$为预测对数分数，$y_{k,j}$为真实标签，CE为交叉熵，$M\,ask_{k,j}$为有效样本分类函数，当为无效标签时不计入损失计算，ω为权重函数，当$y_{k,j}=0$时，$\omega=\lambda_c$其余时为$\omega=1$。

3　实验与结果分析

3.1　实验设置

3.1.1 训练与实现设置

本文采用 PyTorch 作为深度学习模型的实现框架，训练阶段采用 Adam 优化器对网络参数进行更新，初始学习率设为1×10^{-3}，batch size 设置为 32，总训练轮数设置为 100，实验在 Windows 10 操作系统下进行，硬件平台配置为 Intel Core i5 12400F 处理器、NVIDIA GeForce RTX 4060Ti 显卡和 16GB 内存，具体网络参数设置如表 1 所示。

由于关联特征中的径向速度分量由状态变量经非线性投影得到，因此本文的多目标跟踪算法中使用的是基于匀速运动模型的扩展卡尔曼滤波算法[21]，并对完成关联的量测点进行基于 RCS 加权的聚类处理，以聚类质心实现目标航迹更新，并将更新状态存入历史状态用于后续时刻的迭代跟踪。

在构造残差序列时，为避免历史不足 4 帧的目标判为无效而影响新生或者短时航迹的训练，本文对缺失的历史时刻回溯查找距离当前最近的可用航迹状态，并将其复制填充到缺失位置，使每条航迹的历史输入始终保持固定长度。该策略在不改变网络输入维度与时序建模结构的前提下，保证了短历史航迹同样能够形成完整的残差序列并参与关联判别，从而提升模型的适应性。

表 1 网络参数设置

Table 1 Network parameter settings

参数	数值
历史序列长度 H	4
输入特征维度 D	4
航迹历史输入数据维度	$N_{max}\times4\times4$
量测输入数据维度	$M_{max}\times4$
残差序列输入数据维度	$M_{max}\times(N_{max}+1)\times4\times4$
输出数据维度	$M_{max}\times(N_{max}+1)$
单帧最大量测数M_{max}	200
单帧最大航迹数N_{max}	64
GRU 层数	1
GRU 隐状态维度	64
MLP 层数	2
MLP 隐层维度	64
输出层维度	1
Dropout 率	0.1

3.1.2 评价指标

为同时衡量多目标跟踪结果在定位精度与目标数精度两方面的误差，本文采用最优子模式分配距离(Optimal SubPattern Assignment, OSPA)[22]作为主要评价指标。设第k帧真实目

最新录用

标集合为$X_k=\{x_k^{(1)},\ldots,x_k^{(m)}\}$，估计目标集合为$Y_k=\{y_k^{(1)},\ldots,y_k^{(n)}\}$，其中元素可取目标位置状态。当$m\le n$时，OSPA 定义为：

$$d_p^{(c)}(X_k,Y_k)=¿¿$$
¿

其中c为截断阈值，用于控制最大惩罚，p为误差阶数，Π_n表示对n个估计目标的所有排列集合，$\|\cdot\|$为欧式距离。当$m>n$时，OSPA 定义为$d_p^{(c)}(Y_k,X_k)$。

其次，为更直接地评价数据关联模块的分类判定能力，本文引入关联精确率 Precision、召回率 Recall 和 F1 值作为关联评价指标，其中本文实验中采用宏平均方式计算 Precision、Recall 和 F1 值，即先分别计算各类别指标，再对所有类别取平均。F1 值能够同时兼顾误关联和漏关联两类误差，可更全面地反映分类判定准确性。假设所有有效量测中被正确关联的数量为TP，不属于某目标却被错误关联到该目标的数量为FP，真实应关联到某目标但未被正确关联的数量为FN。则关联精确率(Precision)和召回率(Recall)分别定义为：

$$Precision=\frac{TP}{TP+FP} \tag{20}$$

$$Recall=\frac{TP}{TP+FN} \tag{21}$$

结合精确率和召回率，F1 得分定义为它们的调和平均值：

$$F1=\frac{2\times Precision\times Recall}{Precision+Recall} \tag{22}$$

最后，为评估算法在交通多目标跟踪场景中的实时处理能力，本文进一步将平均关联时间引入性能评估体系，在每一帧内统计数据关联模块从输入当前量测与目标航迹集合到输出匹配结果的总耗时，并计算其平均值。

3.1.3 仿真数据集与场景设置

本文面向路侧毫米波雷达交通场景构建了扩展目标仿真数据集。仿真中毫米波雷达安装于路侧固定位置(15,0)m，主视向指向道路纵向，最大探测距离为 220m，水平视场角为 120°。场景道路采用三车道直线路段，目标车辆在[-10,260]m 的纵向范围内行驶。每个场景包含多辆车辆，车辆运动由同向行驶，并行行驶以及变道超车组合构成，用于仿真交通场景中易产生关联问题的密集场景。同时在车辆横向位置与纵向速度叠加平滑扰动以模拟车道内微摆与轻微加减速。

图 6 给出了路侧毫米波雷达视场内扩展目标量测生成示意图。本文仿真中根据车辆真实状态和扩展目标散射点模型生成量测，并叠加距离、角度、径向速度噪声、漏检和杂波以模拟实际路侧毫米波雷达点云输出。

图中包括路侧固定安装雷达、扇形探测视场、视场内目标车辆、目标运动轨迹、车辆扩展目标散射点以及两类杂波分布形式。其中，红色点表示目标车辆产生的扩展目标散射点；浅色点表示静态反射带杂波，用于模拟道路护栏、墙体等固定反射物产生的连续干扰深色点表示均匀随机杂波，用于模拟雷达检测过程中的随机虚警点。

最新录用

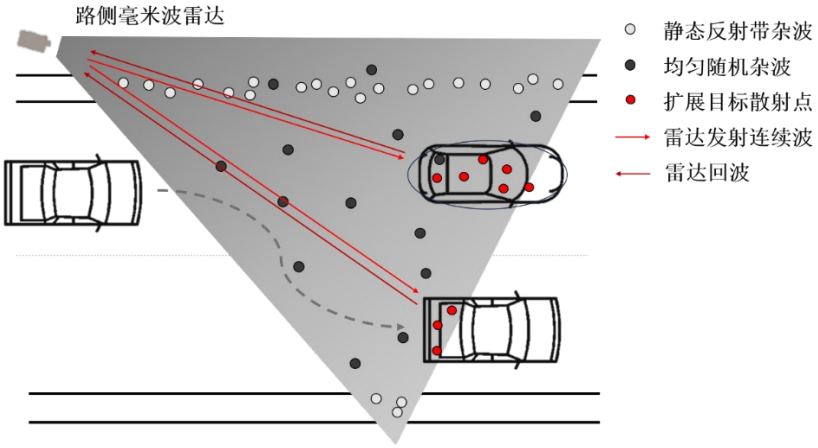


图 6 路侧毫米波雷达视场内扩展目标量测生成示意图

Fig. 6 Schematic of extended-target measurement generation within the field of view of a roadside millimeter-wave radar

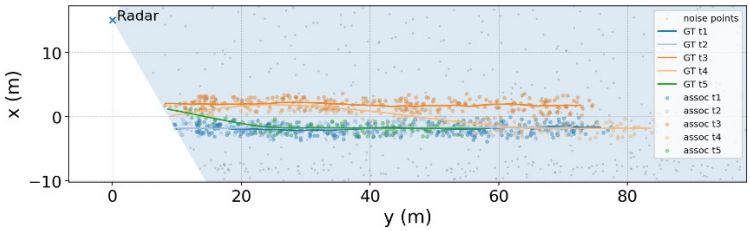
数据集采用离散时间步长$\Delta t=0.1s$，每个场景长度为 60 帧到 100 帧，共生成 100 个场景，其中 80%用于训练集，10%用于验证集，10%用于测试集。在量测生成方面，车辆被建模为扩展目标，每帧采用泊松分布为每个目标仿真最多 8 个散射点，散射点状态由真实极坐标r,α和径向速度v_r加入高斯噪声得到，其中距离、方位与径向速度噪声标准差分别设为$\sigma_r=0.25m$、$\sigma_\alpha=0.4^\circ$、$\sigma_{v_r}=0.35\ m/s$。场景噪声由两类杂波产生，一类为静态反射带杂波，沿固定横向位置带状区域产生，用于仿真路侧墙壁或者护栏；另一类为服从泊松强度的均匀分布杂波。同时设置检测概率 Pd 用于模拟量测缺失情况。

3.2 实验结果与分析

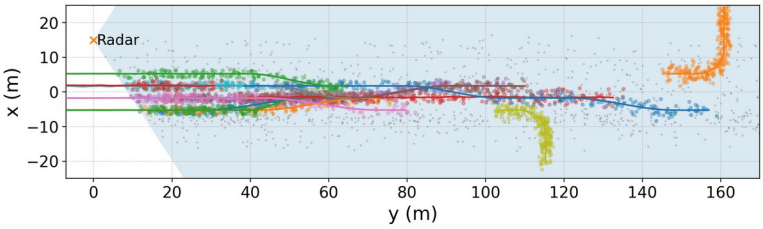
3.2.1 测试场景说明

为验证算法性能，本文选取未参与训练的仿真场景作为测试数据，测试场景如图 7 所示。其中，图 7(a)为常规场景，均匀随机杂波泊松强度为 20，静态反射带杂波泊松强度为 6。该场景包含 5 个目标，GT 表示目标真实轨迹，assoc 表示对应的真实目标量测。各目标在雷达视场内沿纵向行驶，并存在并行行驶、变道超车和近距离交互等情况，用于验证算法在常规交通条件下的数据关联与跟踪性能。

为进一步验证算法在复杂交通条件下的鲁棒性，本文构建了图 7(b)所示的综合复杂场景。该场景在常规场景基础上增加了目标数量和杂波强度，并引入强机动变道、近距离并行、连续漏检和高杂波干扰等因素，用于模拟复杂路侧交通环境中的目标密集交互、遮挡漏检和杂波混杂问题。



(a)常规场景



(b)综合复杂场景

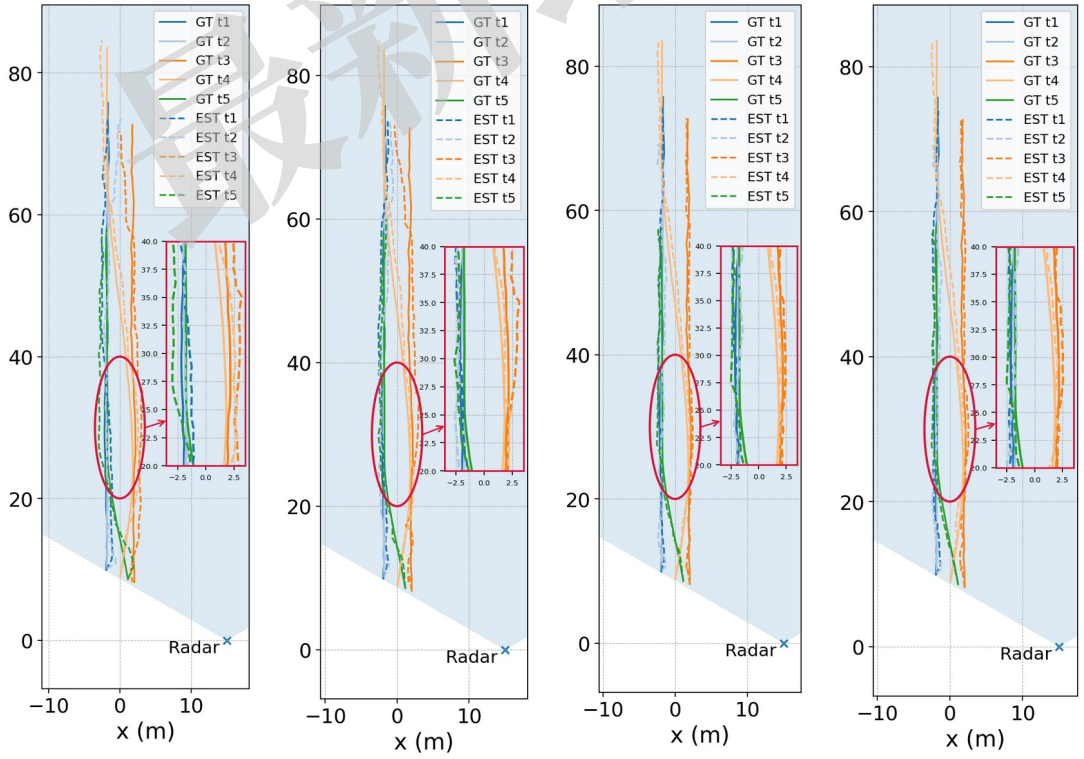
图 7 测试场景

Fig. 7 Test scenarios: (a) normal scenario; (b) comprehensive complex scenario

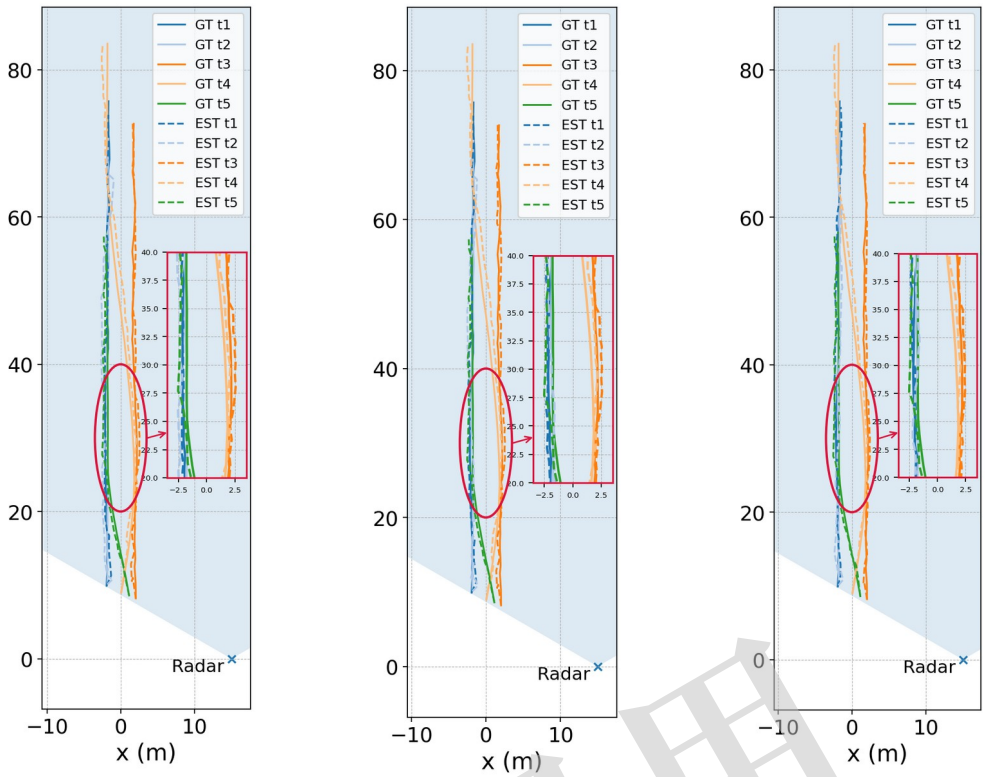
3.2.2 不同算法性能对比分析

为了验证所提短时 GRU 数据关联算法的有效性，本章选取传统数据关联方法中的 JPDA 与 GNN 算法作为基线，并与 Verma 等人提出的以预测状态与当帧量测残差为输入的 BiLSTM 数据关联模型[9]进行对比实验。为进一步评估 GRU 在短时序建模任务中的优势与适用性，本文在保持整体框架与输入输出形式一致的条件下，将关联网络替换为 LSTM，TCN-GRU[23]和 Transformer 网络结构，并在检测概率 Pd=0.92、Pd=0.70 以及综合复杂场景下进行实验。

图 8、图 11(a)和表 2 给出了 Pd=0.92 条件下的实验结果。可以看出，在检测概率较高时，各算法均能实现基本跟踪，但传统 GNN 和 JPDA 在目标近距离并行区域仍存在轨迹偏移现象。GNN 采用单帧硬匹配策略，难以适应扩展目标多量测归属问题；JPDA 虽然引入关联概率，但在波门重叠和杂波干扰条件下，关联概率容易受到相邻目标量测影响。相比之下，深度学习方法整体跟踪效果更好。本文 GRU 算法通过短历史残差序列刻画量测与航迹之间的动态一致性，取得最低 OSPA 距离 0.493m，Recall 和 F1 值均为 0.863，且平均关联时间仅为 0.900ms，说明其在高检测概率条件下兼具跟踪精度和实时性。



(a)GNN (b)JPDA (c)LSTM (d)TCN-GRU



(e)BiLSTM (f)Transformer (g)GRU

图 8 Pd=0.92 下不同算法跟踪结果

Fig. 8 Tracking results of different algorithms at Pd = 0.92

图 9、图 11(b)和表 3 给出了 Pd=0.70 条件下的实验结果。随着检测概率降低，漏检现象增多。GNN 和 JPDA 的 OSPA 距离明显增大，说明传统方法对漏检和复杂量测分布较为敏感。LSTM、TCN-GRU、BiLSTM 和 Transformer 等方法虽然能够在一定程度上改善关联效果，但仍受到模型结构复杂度和噪声扰动的影响，跟踪结果存在不同程度波动。本文 GRU 算法的 OSPA 距离为 0.743m，在所有算法中最低；Recall 和 F1 值分别为 0.852 和 0.841，均为最优，表明其在低检测概率条件下能够更好地兼顾误关联抑制和真实量测召回。

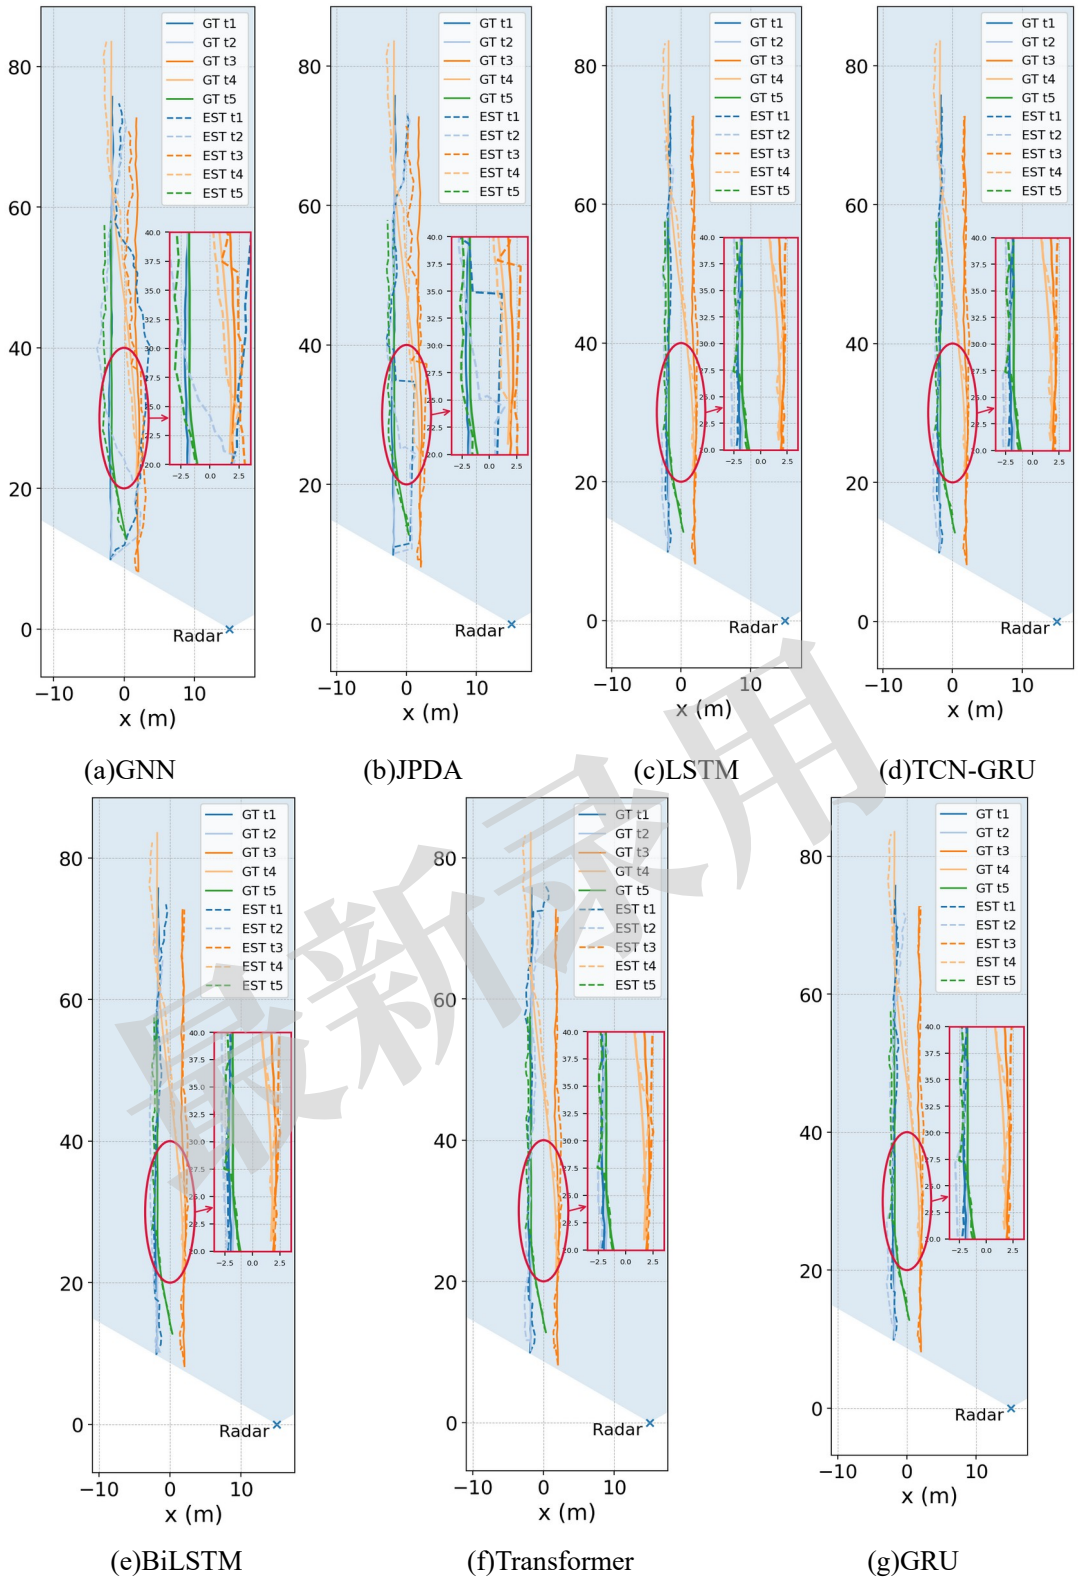
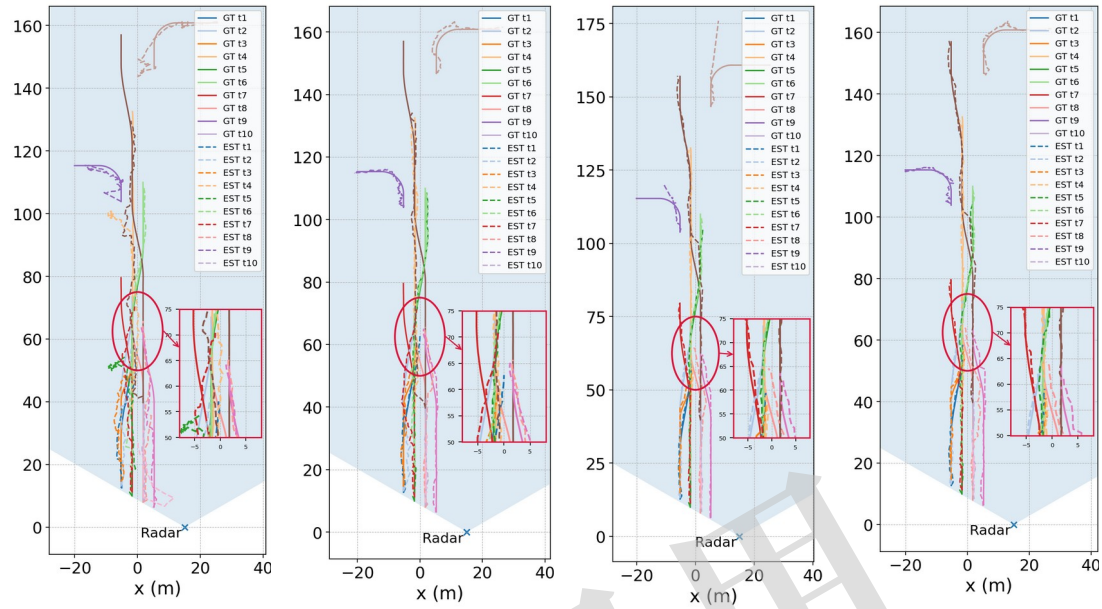


图 9 Pd=0.70 下不同算法跟踪结果

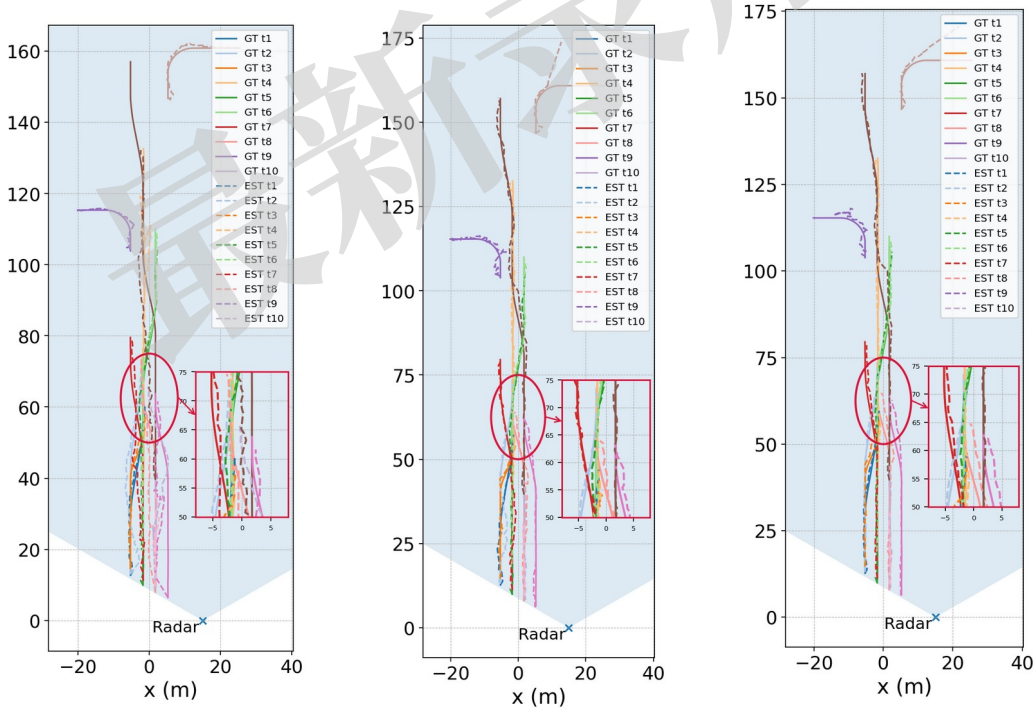
Fig. 9 Tracking results of different algorithms at Pd = 0.70

Error: Reference source not found图 10、图 11(c)和表 4 给出了综合复杂场景下的实验结果。该场景同时包含高目标密度、强机动变道、近距离并行、连续漏检和高杂波干扰等因素。GNN 和 JPDA 在复杂场景下受目标密集交互和杂波影响较大，估计轨迹偏差明显；BiLSTM 在连续漏检和近距离并行条件下也存在关联不稳定现象。相比之下，本文

GRU 算法能够保持较为稳定的轨迹估计，其 OSPA 距离为 0.948m，低于其他对比算法。同时，本文方法的 Recall 和 F1 值分别达到 0.916 和 0.915，均为最优，说明其在复杂场景下具有更强的真实量测识别能力和综合关联性能。平均关联时间为 0.857ms，满足实时跟踪需求。



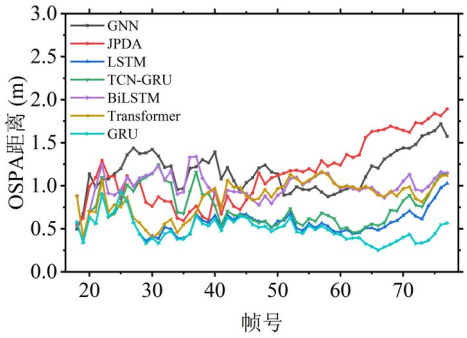
(a)GNN (b)JPDA (c)LSTM (d)TCN-GRU



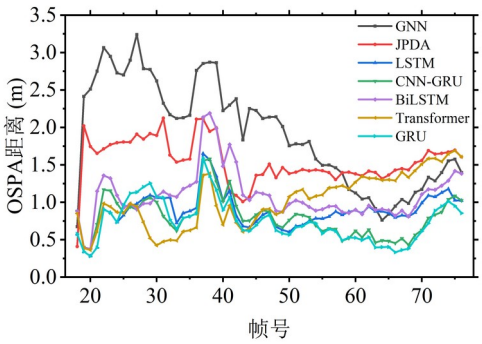
(e)BiLSTM (f)Transformer (g)GRU

图 10 综合复杂场景下不同算法跟踪结果

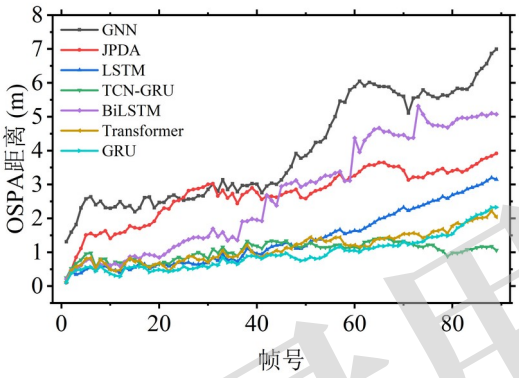
Fig. 10 Tracking results of different algorithms in the comprehensive complex scenario



(a)Pd=0.92 下不同算法 OSPA 距离



(b)Pd=0.70 下不同算法 OSPA 距离



(c)综合复杂场景下不同算法 OSPA 距离

图 11 不同场景下不同算法 OSPA 距离

Fig. 11 OSPA distances of different algorithms in different scenarios

表 2 Pd=0.92 条件下各算法的性能对比

Table 2 Performance comparison of different algorithms at Pd = 0.92

算法	OSPA 距离 (m)	Precision	Recall	F1	关联时间 (ms)
GNN	1. 171	0. 718	0. 330	0. 387	1. 257
JPDA	1. 003	0. 832	0. 801	0. 816	12. 898
LSTM	0. 586	0. 863	0. 858	0. 853	1. 355
TCN-GRU	0. 753	**0. 872**	0. 856	0. 852	5. 660
BiLSTM[9]	0. 993	0. 831	0. 829	0. 830	0. 960
Transformer	0. 861	0. 866	0. 849	0. 848	1. 758
本文 GRU 算法	**0. 493**	0. 867	**0. 863**	**0. 863**	**0. 900**

表 3 Pd=0.70 条件下各算法的性能对比

Table 3 Performance comparison of different algorithms at Pd = 0.70

算法	OSPA 距离 (m)	Precision	Recall	F1	关联时间 (ms)
GNN	1. 895	0. 543	0. 305	0. 341	0. 953
JPDA	1. 522	0. 616	0. 590	0. 600	8. 269
LSTM	0. 881	**0. 885**	0. 851	0. 827	**0. 803**
TCN-GRU	0. 803	0. 862	0. 838	0. 832	3. 216

最新录用

BiLSTM[9]	1.096	0.776	0.771	0.772	0.888
Transformer	1.023	0.770	0.781	0.766	1.731
本文 GRU 算法	**0.743**	0.856	**0.852**	**0.841**	0.836

表 4 综合复杂场景条件下各算法的性能对比

Table 4 Performance comparison of different algorithms in the comprehensive complex scenario

算法	OSPA 距离 (m)	Precision	Recall	F1	关联时间 (ms)
GNN	3.989	0.532	0.218	0.288	6.187
JPDA	2.713	0.790	0.717	0.744	50.067
LSTM	1.382	**0.956**	0.856	0.871	0.900
TCN-GRU	1.025	0.929	0.889	0.896	3.368
BiLSTM[9]	2.711	0.720	0.688	0.685	1.014
Transformer	1.127	0.944	0.899	0.912	1.668
本文 GRU 算法	**0.948**	0.933	**0.916**	**0.915**	**0.857**

综上，传统关联算法在扩展目标多散射点、杂波和漏检条件下容易受到单帧量测不确定性的影响；复杂深度学习模型虽然具有较强表达能力，但在短时序、小样本和实时关联任务中并不一定具有优势。本文短时 GRU 数据关联算法通过构造量测与航迹短历史状态之间的残差序列，能够有效提取短时动态一致性特征，并以较低计算复杂度完成关联判定。因此，本文方法在不同检测概率和综合复杂场景下均取得了较低的 OSPA 距离、较高的 F1 值和较短的关联时间，验证了其有效性、鲁棒性和实时性。

3.2.3 短历史长度对比实验分析

为分析历史长度H对关联性能的影响，本文分别设置$H=1,2,4,8$进行对比实验，并采用多条测试场景平均 OSPA 距离评价跟踪性能。如表 5 所示，当$H=1$时，模型退化为主要利用当前量测与单帧历史状态之间的残差信息，短时动态信息不足，因此在目标近距离交互和漏检条件下容易出现关联不稳定。随着H增大，模型能够利用更多历史状态刻画量测与航迹之间的短时运动一致性，OSPA 距离整体降低。当H继续增大到 8 时，较早历史状态与当前关联判定的相关性减弱，输入序列变长会增加模型学习难度，因此性能提升不再明显，甚至可能出现波动。综合 OSPA 距离和计算复杂度，本文选取$H=4$作为短历史残差序列长度。

表 5 不同历史长度 H 下的平均 OSPA 距离对比

Table 5 Comparison of average OSPA distances for different history lengths H

历史长度H	1	2	4	8
OSPA 距离(m)	0.675	0.670	**0.532**	0.637

4 结束语

本文针对路侧毫米波雷达交通场景中数据关联问题，提出了一种短时 GRU 数据关联方法。该方法以当帧量测与目标航迹短历史状态为基础，在统一状态空间下构造量测与目标航迹的残差序列，随后利用短时 GRU 关联网络得到关联概率，实现扩展目标场景下的多量测归属判定。该框架在端到端训练中学习复杂交通背景下的关联判别规律。同时，针对扩展目标单帧可产生多个量测点的特点，本文允许同一航迹在同一时刻接收多个关联量测，为目标状态更新提供聚类质心支持。

本文在构建的路侧固定雷达扩展目标仿真数据集上与不同算法进行对比。实验结果表

明，在不同场景条件下，本文所提方法均取得了较小的 OSPA 距离和较高的 F1 值，表明该方法在关联精度与整体跟踪性能方面具有较好表现，且对复杂场景变化的敏感性更低，表现出更好的稳定性。同时，所提方法在关联耗时方面更符合交通多目标跟踪的实时性需求说明本文方法在复杂交通交互、连续漏检以及近距离并行等场景下，能够较好兼顾关联精度、稳定性以及实时性。后续将进一步结合真实路侧毫米波雷达数据，并从距离、角度和径向速度误差变化角度分析量测误差对 OSPA 距离的影响，以更全面验证算法在真实复杂交通环境中的泛化能力。

参考文献：

[1] Rao S. Introduction to mmWave sensing: FMCW radars[J]. Texas Instruments (TI) mmWave Training Series, 2017: 1-11.

[2] 李天成，谢昱昕，李固冲，等.面向多目标跟踪的数据关联方法研究综述［J］.雷达科学与技术，2025，23（1）：10-31.
LI Tiancheng, XIE Yuxin, LI Guchong, FAN Hongqi. A survey on data association approaches to multi-target tracking[J]. Radar Science and Technology, 2025, 23(1): 10-31.

[3] Wang J, He P, Coo W. Study on the Hungarian algorithm for the maximum likelihood data association problem[J]. Journal of Systems Engineering and Electronics, 2007, 18(1): 27-32.

[4] Fukunaga K, Flick T E. An optimal global nearest neighbor metric[J]. IEEE transactions on Pattern analysis and Machine Intelligence, 1984 (3): 314-318.

[5] Chang K C, Bar-Shalom Y. Joint probabilistic data association for multitarget tracking with possibly unresolved measurements and maneuvers[J]. IEEE Transactions on Automatic control, 1984, 29(7): 585-594.

[6] Lee M, Xiong Y, Yu G, et al. Deep neural networks for linear sum assignment problems[J]. IEEE Wireless Communications Letters, 2018, 7(6): 962-965.

[7] Milan A, Rezatofighi S, Garg R, et al. Data-driven approximations to NP-hard problems[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2017, 31(1).

[8] Liu H, Zhang H, Mertz C. DeepDA: LSTM-based deep data association network for multi-targets tracking in clutter[C]//2019 22nd international conference on information fusion (FUSION). IEEE, 2019: 1-8.

[9] Verma R, Rajesh R, Easwaran M S. Modular multi target tracking using LSTM networks[J]. arXiv preprint arXiv:2011.09839, 2020.

[10] Wu G, Wang L, Hu X, et al. BiGRU-DA: Based on Improved BiGRU Multi-Target Data Association Method[C]//2023 8th International Conference on Computer and Communication Systems (ICCCS). IEEE, 2023: 1125-1130.

[11] 李文娜，张顺生，王文钦. 基于 Transformer 网络的机载雷达多目标跟踪方法[J]. 雷达学报，2022, 11(3): 469－478.
LI Wenna, ZHANG Shunsheng, WANG Wenqin. Multitarget-tracking method for airborne radar based on a transformer network[J]. Journal of Radars, 2022, 11(3): 469-478. DOI: 10.12000/JR22009.

[12] Liu J, Luo L, Gao J, et al. Radar Multi-Target Tracking Data Association Method Based on Transformer[C]//2025 6th International Conference on Computer Engineering and

最新录用

Intelligent Control (ICCEIC). IEEE, 2025: 448-451.
[13] Cho K, Van Merriënboer B, Gulçehre Ç, et al. Learning phrase representations using RNN encoder‐decoder for statistical machine translation[C]//Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP). 2014: 1724-1734.
[14] Han P, Wang W, Shi Q, et al. Real-time short-term trajectory prediction based on GRU neural network[C]//2019 IEEE/AIAA 38th Digital Avionics Systems Conference (DASC). IEEE, 2019: 1-8.
[15] Xiaoyan H, Bingjie L, Jing S, et al. A novel forecasting method for short-term load based on TCN-GRU model[C]//2021 IEEE international conference on energy internet (ICEI). IEEE, 2021: 79-83.
[16] Boucetta L N, Amrane Y, Arezki S. Comparative analysis of LSTM, GRU, and MLP neural networks for short-term solar power forecasting[C]//2023 international conference on electrical engineering and advanced technology (ICEEAT). IEEE, 2023, 1: 1-6.
[17] Zelios V, Mastorocostas P, Kandilogiannakis G, et al. Short-term electric load forecasting using deep learning: a case study in Greece with RNN, LSTM, and GRU networks[J]. Electronics, 2025, 14(14): 2820.
[18] Zhao S, Xu Z, Zhu Z, et al. Short and long-term renewable electricity demand forecasting based on cnn-bi-gru model[J]. ICCK Transactions on Emerging Topics in Artificial Intelligence, 2025, 2(1): 1-15.
[19] Rumelhart D E, Hinton G E, Williams R J. Learning representations by back-propagating errors[J]. Nature, 1986, 323(6088): 533-536.
[20] Bridle J S. Probabilistic interpretation of feedforward classification network outputs, with relationships to statistical pattern recognition[M]//Neurocomputing: Algorithms, architectures and applications. Berlin, Heidelberg: Springer Berlin Heidelberg, 1990: 227-236.
[21] Applied optimal estimation[M]. MIT press, 1974.
[22] Ristic B, Vo B N, Clark D, et al. A metric for performance evaluation of multi-target tracking algorithms[J]. IEEE Transactions on Signal Processing, 2011, 59(7): 3452-3457.
[23] Bai S, Kolter J Z, Koltun V. An empirical evaluation of generic convolutional and recurrent networks for sequence modeling[J]. arXiv preprint arXiv:1803.01271, 2018.

最新录用

作者简介：

徐安策　男，2001年生，硕士生，主要研究方向为毫米波雷达多目标跟踪。
王目光　男，1978年生，博士，教授，主要研究方向为微波光子雷达、光通信与光传感。
陈　欣　女，2000年生，硕士生，主要研究方向为毫米波雷达多目标跟踪。
苏　昊　男，1998年生，博士生，主要研究方向为微波光子雷达通信一体化。
王　健　男，2000年生，博士生，主要研究方向为光电混沌系统、微波光子。
孙　亮　男，1999年生，硕士生，主要研究方向为感知深度学习数据处理。